


El Algoritmo del Gradiente Descendente

Optimización matemática para Deep Learning




El Objetivo Principal: Encontrar el Mínimo

El entrenamiento de un modelo de Deep Learning consiste en ajustar perillas hasta lograr el comportamiento deseado.


El Gradiente Descendente es el motor que gobierna este movimiento.

Misión: Encontrar de forma iterativa y automática el punto mínimo absoluto de una función matemática.




El Terreno Matemático: La Función Cuadrática

$$y = (x - 2)^2$$



La Derivada como Brújula



Magnitud y Dirección: La inclinación dicta la urgencia del movimiento. El signo dicta la dirección. A medida que nos acercamos al mínimo, la magnitud se encoge hasta llegar a cero.

Anatomía de la Actualización

Nuevo Valor: La posición actualizada en la iteración actual.


Valor Actual: Nuestra posición inicial o previa.

$$x_{k+1} = x_k - \alpha \frac{dy}{dx}$$


Tasa de Aprendizaje (Alfa): El multiplicador del paso. Un valor entre 0 y 1 que define qué tan agresivo es nuestro movimiento.

El Gradiente: La derivada en el punto actual que nos indica la pendiente del terreno.

El Ciclo de Optimización Iterativa



El Descenso en Acción (Desde la Izquierda)



$\alpha = 0.4$ | Inicio: $x = 0.5$

Iteración 1: Inicia en $x = 0.5$ (Derivada: -3)

Iteración 2: Salta a $x = 0.7$


Iteración 3: Salta a $x = 1.94$

Iteración 4: Alcanza $x \approx 1.99$

El avance es progresivo. A medida que el gradiente pierde magnitud, los pasos se acortan automáticamente, evitando sobrepasar el objetivo.

Simetría del Algoritmo (Desde la Derecha)


$\alpha = 0.4$ | Inicio: $x = 5.0$



Insight note

Independientemente del punto de partida aleatorio, la dirección negativa de la pendiente siempre empuja el valor hacia el centro absoluto ($x=2$).

El Parámetro Crítico: La Tasa de Aprendizaje (α)




$$- \alpha \cdot \left(\frac{dy}{dx} \right)$$

El Límite Inferior (0): El término se anula. El algoritmo queda completamente estancado.

El Límite Superior (1): Restamos el máximo valor posible del **gradiente**.


El Reto: α es un hiperparámetro que se debe ajustar cuidadosamente. Un valor incorrecto destruye la **convergencia**.

Caso de Error: Alfa Muy Grande



- Si α es excesivo, el salto supera el centro de la curva.
- En lugar de descender, el punto rebota de un lado a otro, alcanzando posiciones cada vez más altas.
- Resultado: El algoritmo nunca encuentra el mínimo. Falla en converger.


Caso de Error: Alfa Muy Pequeño



- Si α es cercano a cero, las actualizaciones del peso son minúsculas.
- El algoritmo avanza en la dirección correcta, pero requiere una cantidad masiva de iteraciones computacionales.
- Resultado: Convergencia garantizada matemáticamente, pero ineficiente y computacionalmente costosa en la práctica.


Matriz de Diagnóstico de la Tasa de Aprendizaje

Alfa Muy Pequeño




Diagnóstico: Lento, ineficiente, alto costo computacional.

Alfa Óptimo



Diagnóstico: Eficiente, rápido, pasos auto-ajustables.

Alfa Muy Grande



Diagnóstico: Divergencia, inestabilidad, fracaso del modelo.

Resumen de Ejecución del Algoritmo


Algoritmo

Parámetros Iniciales

1. **Punto de Inicio:** Seleccionado de forma aleatoria.
2. **Tasa de Aprendizaje (α):** Ajustada a prueba y error (entre 0 y 1).
3. **Límite de Iteraciones:** Límite máximo de repeticiones para forzar la detención.

Ciclo Activo

Fórmula de ejecución repetitiva:

$$x_{k+1} = x_k - \alpha \frac{dy}{dx}$$
The diagram illustrates the iterative nature of the formula. A horizontal line connects the x_k term in the denominator of the derivative to the x_k term in the numerator. From the end of this line, a vertical arrow points down to the x_k term in the numerator. Another vertical arrow points up from the x_k term in the denominator to the horizontal line, completing the loop.

Nota: Actualmente, no existe una fórmula analítica perfecta para predecir los parámetros ideales; requiere experimentación heurística.

Hacia el Machine Learning y Deep Learning

El Gradiente Descendente no es solo una curiosidad matemática.

Es el bloque fundacional para entrenar modelos predictivos, desde una regresión lineal básica hasta arquitecturas complejas de Redes Neuronales.

Comprender su comportamiento, y su sensibilidad a α , es el primer paso indispensable para la arquitectura de Deep Learning.

