



El bloque constitutivo fundamental del Deep Learning




Comprendiendo la estructura íntima de las redes neuronales a través de la clasificación matemática de datos.

El desafío inicial para clasificar el rendimiento académico



Dado un número de horas de sueño (x_1) y horas de estudio (x_2), el objetivo es predecir la categoría del estudiante. Nos alejamos de la regresión continua para resolver un problema de Clasificación Binaria mediante aprendizaje supervisado.

La intuición geométrica para separar las categorías



Si logramos calcular automáticamente la posición exacta de esta línea recta, podemos clasificar cualquier dato nuevo. Un punto ubicado por debajo de la frontera representa un puntaje alto; un punto por encima representa un puntaje bajo.

Transformando la geometría plana en álgebra vectorial

Ecuación clásica de la recta

$$x_2 = mx_1 + b$$



Igualación a cero

$$x_2 - mx_1 - b = 0$$



Forma compacta vectorial


$$W \cdot X + b = 0$$

W = Vector de coeficientes (Pesos)

X = Vector de características
(Horas de sueño y estudio)

b = Intersección (Sesgo escalar)


Definiendo la topología matemática del espacio de decisión



$$Z = W \cdot X + b$$

La operación matricial define el estado espacial del dato. El resultado numérico de la operación determina de manera absoluta a qué categoría pertenece cada estudiante analizado.


El primer acercamiento computacional con el Perceptrón de 1958



El Perceptrón original tomaba el resultado escalar de la transformación matemática y lo sometía a un umbral estricto mediante la Función Escalón. El cambio de categoría era instantáneo y abrupto, sin valores intermedios.

La evolución hacia una clasificación matemáticamente gradual


El Perceptrón



Función Escalón

Cambios matemáticos abruptos e instantáneos.

La Neurona Artificial




Función de Activación No Lineal

Transiciones graduales y derivables.

La linealidad reside en la transformación de los datos, pero asignar categorías requiere romper esa linealidad. La neurona moderna abandona la rigidez del escalón a favor de una curva suave, un requisito indispensable para permitir el aprendizaje continuo de la red.


La anatomía de la Función Sigmoidal

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$





Esta función comprime cualquier valor numérico, por extremo que sea, dentro de un rango seguro entre 0 y 1, permitiendo evaluar la probabilidad de pertenencia a una categoría.

El diagrama de flujo interno de la Neurona Artificial



El bloque fundamental del Deep Learning ejecuta un proceso secuencial estricto: recibe características, aplica una transformación afín y filtra el resultado mediante una activación no lineal para emitir un juicio definitivo.

El paralelismo estructural con el procesamiento cerebral



El modelo artificial emula el principio biológico básico: recopilar señales de excitación, ponderar su relevancia colectiva y disparar una respuesta matemática hacia las capas subsiguientes de la red.

El eslabón pendiente: El descubrimiento de los parámetros

$$w^? \cdot X + b^? = 0$$

Comprendemos la arquitectura del modelo y la topología del espacio de decisión.

Los datos (X) son **inmutables**.


Sin embargo, ¿cómo descubre la neurona, de manera completamente automática, los coeficientes exactos (W y b) necesarios para trazar la frontera perfecta?

Siguiente fase: El proceso de Entrenamiento.

Entrenamiento de Neuronas y Entropía Cruzada

De la arquitectura básica a la optimización de la pérdida en clasificación.

Anatomía de la Neurona Artificial




El Fracaso del Error Cuadrático Medio en Clasificación

Una penalización máxima de 1 es matemáticamente insuficiente para corregir la ignorancia confiada.

$$\text{MSE} = (y - \hat{y})^2$$

Escenario A (Falso Positivo):
Target (y) = 0. Predicción ($\hat{y}$) = 1.
Error = $(0-1)^2 = 1$.

Escenario B (Falso Negativo):
Target (y) = 1. Predicción ($\hat{y}$) = 0.
Error = $(1-0)^2 = 1$.



La Solución: Entropía Cruzada

Una función diseñada para castigar severamente los errores de alta confianza.

$$Loss = - \left[\underbrace{y \cdot \ln(\hat{y})}_{\substack{\text{Se activa cuando} \\ \text{Target} = 1}} + \underbrace{(1 - y) \cdot \ln(1 - \hat{y})}_{\substack{\text{Se activa cuando} \\ \text{Target} = 0}} \right]$$

Comportamiento de Pérdida cuando Target = 1

$$Loss = -\ln(\hat{y})$$



Comportamiento de Pérdida cuando Target = 0


$$Loss = -\ln(1 - \hat{y})$$



Consolidación del Error: La Pérdida Global (J)

Promediando la entropía cruzada a través de m datos de entrenamiento.

$$J(\mathbf{W}, \mathbf{b}) = -\frac{1}{m} \sum_{i=1}^m [y_i \ln(\hat{y}_i) + (1 - y_i) \ln(1 - \hat{y}_i)]$$



La predicción $\hat{y}_i$ depende directamente de los pesos $\mathbf{W}$ y el sesgo $\mathbf{b}$.
Para minimizar J , debemos ajustar estos parámetros.


El Motor de Aprendizaje: Gradiente Descendente

La entropía cruzada crea el terreno; el gradiente descendente lo navega.

$$W_{\text{nuevo}} = W_{\text{anterior}} - \alpha \nabla_W J$$

$$b_{\text{nuevo}} = b_{\text{anterior}} - \alpha \nabla_b J$$

El algoritmo permanece idéntico al de la regresión lineal. Solo cambia la topología del error.



Matriz de Decisión Analítica

	MSE (Error Cuadrático Medio)	Entropía Cruzada
Penalización Máxima por Dato	1	∞ Infinito
Castigo a Errores de Alta Confianza	Bajo / Insuficiente	Severo y Exponencial
Caso de Uso Matemático Ideal	Regresión (Valores continuos)	• Clasificación (Probabilidades 0 a 1)