



Algoritmos de Optimización para Redes Neuronales Profundas: Fundamentos y Mecánica Matemática.

Del Descenso de Gradiente Estocástico (SGD) a la estimación adaptativa (Adam). Una progresión geométrica y cinética.



El Problema de la Convergencia en SGD: Asimetría Topológica

$$\theta_{t+1} = \theta_t - \eta \nabla f(\theta_t)$$



El Paradigma:

SGD actualiza los pesos basándose estrictamente en el gradiente local del mini-batch actual.

La Falla Estructural:


En terrenos elongados, el gradiente apunta hacia las paredes del valle, no hacia el mínimo. Esto genera alta oscilación y requiere reducir drásticamente la tasa de aprendizaje (η), haciendo la convergencia letárgica.

Métrica de Ineficiencia:

La distancia para llegar al centro escala como $\kappa \log(1/\epsilon)$.

Momentum (Impulso): Intervención Cinética

Física de la Pendiente (Simulación de Inercia)



Mecánica Vectorial (Cancelación y Acumulación)



$$v_t = \beta v_{t-1} + (1 - \beta) \nabla \theta_t$$


Concepto: Propuesto por Polyak (1964), Momentum simula inercia. En lugar de moverse solo por el gradiente actual, incorpora una fracción de la velocidad anterior.

El Hiperparámetro β : Configurar $\beta = 0.9$ equivale a utilizar el promedio ponderado de, aproximadamente, los últimos 10 gradientes ($1 / (1 - \beta)$).

Resultado Teórico: La distancia de convergencia mejora drásticamente a $\sqrt{(\kappa)} \log(1/\epsilon)$.

Gradiente Acelerado de Nesterov (NAG): Anticipación Espacial

$$\theta_{t+1} = \theta_t - \eta \nabla f(\theta_t + \alpha \mathbf{v}_{t-1}) + \alpha \mathbf{v}_{t-1}$$




Concepto (Yurii Nesterov, 1983):

Mirar hacia adelante antes de actuar.

Ventaja Mecánica:

El vector de impulso generalmente apunta en la dirección correcta. Medir el gradiente después de aplicar el impulso proporciona una corrección de rumbo mucho más precisa, frenando a la bola de bolos antes de que suba la ladera opuesta del valle.

RMSProp: Normalización Espacial por Dimensión



$$s_t = \beta s_{t-1} + (1 - \beta)(\nabla \theta_t)^2$$

Actualización dividida por: $\sqrt{s_t + \epsilon}$

La Limitación de la Cinética:

Momentum estabiliza la oscilación pero no aborda directamente la asimetría de la escala de características (diferentes rangos de pendiente). Adagrad intentó esto, pero su tasa de aprendizaje decaía tan rápido que el entrenamiento moría prematuramente.


La Solución RMSProp:

Rastrea el promedio móvil decreciente exponencialmente de los cuadrados de los gradientes.

Mecánica Base:

Dimensiones con oscilaciones empinadas generan s_t grandes; al dividir por la raíz de s_t , se frena esa dimensión. Dimensiones planas generan s_t pequeños, acelerando su avance. ϵ previene la división por cero.

Adam (Adaptive Moment Estimation): La Síntesis Arquitectónica



Concepto:

Adam unifica las ventajas históricas. De Momentum adopta la inercia direccional; de RMSProp adopta tasas de aprendizaje adaptativas independientes para cada parámetro.

Hiperparámetros Estándar de la Industria:

- Tasa de decaimiento primer momento (inercia): $\beta_1 = 0.9$
- Tasa de decaimiento segundo momento (escala): $\beta_2 = 0.999$
- Estabilizador numérico: $\epsilon = 10^{-8}$

Adam y el Arranque en Frío: Corrección de Sesgo (Bias Correction)

Corrección de Sesgo Momentum:

$$\hat{v}_t = \frac{v_t}{1 - \beta_1^t}$$

Corrección de Sesgo RMSProp:


$$\hat{s}_t = \frac{s_t}{1 - \beta_2^t}$$

El Problema Operativo:

Al inicializar las variables en 0, las primeras iteraciones sufren un sesgo hacia cero. Sin corrección, en la iteración $t=1$, el paso de actualización depende extremadamente poco del gradiente (ej. apenas $0.1 \nabla W$), causando un arranque letárgico.


La Intervención Matemática:

Se aplica una corrección asintótica. Al dividir los acumuladores entre $(1 - \beta^t)$, se escala el valor inicial hacia arriba. A medida que t crece hacia miles de iteraciones, el denominador tiende a 1, desapareciendo la corrección automáticamente.



Implementación Técnica: De la Pizarra a TensorFlow


```
optimizer = tf.keras.optimizers.RMSprop(  
    learning_rate=0.01,  
    rho=0.9  
)  
optimizer = tf.keras.optimizers.Adam(  
    learning_rate=0.01,  
    beta_1=0.9,  
    beta_2=0.999,  
    epsilon=1e-08  
)
```


$$\beta$$
$$\beta_1$$
$$\beta_2$$
$$\epsilon$$

Restricción y Estandarización: Los frameworks modernos como Keras abstraen la complejidad computacional. La implementación manual del promedio móvil se automatiza.

Nota de Producción: La elección de la tasa de aprendizaje inicial (ej. 1×10^{-2}) sigue siendo el hiperparámetro primario que el ingeniero de datos debe ajustar, mientras que las variables dinámicas de Adam pueden dejarse con sus valores teóricos por defecto.

Evidencia Empírica: Convergencia hacia el 95% de Precisión



El Verbo Físico:

Aunque SGD es la base teórica de la que surgen todos, su ineficiencia espacial y cinética cuesta recursos masivos.

El Impacto Computacional:

Alcanzar el mismo umbral de convergencia con Adam en lugar de SGD reduce el costo de procesamiento por órdenes de magnitud, haciendo viable el entrenamiento de redes profundas modernas.

Taxonomía de Optimizadores: Síntesis Arquitectónica

Algoritmo	Fórmula Base (Condensada)	Mecanismo de Intervención	Manejo de Topologías Irregulares	Épocas (Benchmark 95%)
SGD	$\theta_t - \eta \nabla f(\theta_t)$	Paso local directo	Muy pobre (alta oscilación)	218
Momentum	Integra v_{t-1} (inercia)	Promedio Ponderado Exponencial	Cinético (Cancela ruido)	24
RMSProp	Divide $\nabla \theta_t$ entre $\sqrt{s_{tt}}$	Promedio gradientes cuadrados	Espacial (Escala la topografía)	9
Adam	Combina $\hat{v}_t$ y $\hat{s}_t$	Momentum + Normalización espacial	Perfecto (Adaptación por parámetro)	3

Nota del Ingeniero: Ante fallo en conjuntos de datos donde el decaimiento exponencial colapsa (inestabilidad de momentos), se recomienda hacer fallback a variantes cinéticas puras como Nesterov (NAG).