



Introducción a las Secuencias y Redes Neuronales Recurrentes (RNN)

Modelando la correlación temporal y el orden en el Deep Learning




El límite del dato estático frente al mundo real



Redes Feedforward y Convolucionales (CNNs)

Procesan vectores de tamaño fijo o imágenes individuales.

Asumen independencia estadística total entre las entradas.




El mundo real genera conjuntos de datos secuenciales.

El valor actual está **condicionado intrínsecamente** por el pasado.


Requieren modelar secuencias de datos altamente correlacionados.

Definiendo la anatomía de una secuencia




Un conjunto de elementos ordenados donde la aparición de un valor no es aleatoria; está directamente correlacionada y condicionada por los elementos que le preceden o suceden.

Series temporales financieras



- El **valor** de una **acción** en el instante actual (t) no es un evento aislado.
- **Depende intrínsecamente** de su valor en el instante **anterior** ($t-1$) y condiciona el instante posterior ($t+1$).
- La variable **tiempo** dicta una estricta no-aleatoriedad secuencial.

El lenguaje natural opera a múltiples escalas de resolución




Nivel de Caracteres: La aparición de un carácter guarda relación estricta con el carácter del instante de tiempo anterior.



Nivel de Palabras: La sintaxis dicta que cada palabra está correlacionada temporalmente, condicionando las posiciones futuras en la oración.

Visión espacio-temporal continua




Un video no es un conjunto aleatorio de imágenes independientes.


Es una progresión ordenada donde los frames adyacentes comparten información vital progresiva.

Alterar el orden cronológico destruye inmediatamente la información de movimiento y contexto.

Señales fisiológicas y codificación biológica



ECG / EEG: Las variaciones de amplitud a lo largo del tiempo real mantienen una correlación estricta que indica el estado sistémico actual.




Secuencias de ADN: El tiempo cronológico se sustituye por el orden espacial lineal. Los pares de bases respetan un orden específico no aleatorio vital para la función celular.

La universalidad estructural de la secuencia

Dominio	Elemento Base	Eje de Secuencia	Naturaleza de la Correlación
Finanzas	Valor Numérico	Tiempo Cronológico	Tendencia del Mercado
Lenguaje	Carácter / Palabra	Posición Gramatical	Sintaxis y Semántica
Video	Matriz de Píxeles (Frame)	Tiempo de Reproducción	Flujo de Movimiento
Biología (ADN)	Par de Bases	Posición Espacial Lineal	Función Celular

Estandarización de la entrada computacional



Las redes neuronales requieren representaciones numéricas puras.


Independientemente de su origen (una amplitud fisiológica, un píxel de video o una palabra codificada), cada elemento individual de cualquier secuencia se transforma en una representación matemática unificada: El Vector (x).

La formalización del tiempo y el orden

$$\bar{x} = \{x_1, x_2, \dots, x_t, \dots, x_T\}$$

$\bar{x}$ = La secuencia matemática completa.	x = El vector representativo en un punto dado de la secuencia.	t = El subíndice temporal (el índice de posición relativa dentro del conjunto).
---	--	---


La posición estructural como variable de tiempo



El índice t representa el orden estructural, no solo el tiempo de un reloj.


Precisión Técnica: Al tokenizar texto, los espacios en blanco o caracteres de separación actúan como elementos matemáticos válidos (x_2), manteniendo la integridad de la correlación secuencial.

La falla arquitectónica del Statu Quo



- **Longitud Estática:** Requieren que el vector o la matriz de entrada tengan una dimensionalidad fija y predefinida. (Las secuencias fluctúan en longitud).
- **Amnesia Estructural:** Las redes Feedforward y Convolucionales no poseen mecanismos de memoria interna.
- **Ceguera Condicional:** Al carecer de estado, son matemáticamente incapaces de procesar dependencias condicionadas entre la entrada anterior y la actual.

Hacia una arquitectura con memoria: Redes Neuronales Recurrentes




Para procesar secuencias, se requiere un cambio de paradigma geométrico.

Necesitamos una arquitectura diseñada no solo para observar la entrada actual, sino para retener activamente la información interna del estado pasado.

El siguiente paso: La anatomía interna de las RNNs.

Principio de Funcionamiento de las Redes Neuronales Recurrentes

Procesamiento secuencial y memoria compartida en Deep Learning.




El mundo real ocurre en secuencias

Las arquitecturas tradicionales fallan cuando la información fluye en el tiempo.




Datos Secuenciales



Limitación 1: La rigidez de la entrada

Las redes neuronales clásicas colapsan ante variaciones en la longitud de los datos.




Limitación 2: La ceguera posicional


Un cambio en el orden destruye la interpretación del modelo.

Tienes una **única oportunidad**

Tienes una **oportunidad única**




?



?


Matriz de diagnóstico

Por qué el diseño estático es incompatible con el lenguaje y el tiempo.

	Redes Tradicionales (NN/CNN)	Naturaleza de las Secuencias
Tamaño	Entrada Fija y Rígida 	Longitud Variable 
Procesamiento	Simultáneo (Todo a la vez) 	Flujo en el tiempo (t) 
Contexto	Ceguera posicional 	Significado dependiente del orden 


Principio 1: Ingesta secuencial (x_t)

La red ingiere un único elemento en cada instante de tiempo.



Una única red, múltiples iteraciones


Mismos pesos, mismas neuronas, actuando sobre cada instante de tiempo.



Sin modificar absolutamente nada en su estructura interna

Versatilidad de longitud infinita

Al iterar elemento por elemento, el tamaño total de la secuencia deja de importar.




El eslabón perdido del contexto

Si procesamos cada palabra por separado, ¿cómo recuerda la red lo que acaba de leer?



Principio 2: Memoria e Información Compartida


Una conexión de retroalimentación que transporta el estado anterior.



**El estado interno se
reduco interno
comparte para el
instante $t+1$**

Desenrollando la memoria temporal

Cómo el contexto posicional viaja a través de la secuencia.




El motor dual de las RNN

La combinación que permite a la IA comprender el flujo del tiempo.



Procesamiento Secuencial (x_t)

Ingesta paso a paso de cualquier longitud



Contexto Compartido (Memoria)


Retroalimentación de la iteración anterior

Comprensión integral de secuencias dinámicas

Siguientes pasos: El interior del nodo


Hemos superado la entrada fija y la ceguera al orden. Ahora toca abrir la caja negra.

- ✓ Limitaciones NN/CNN resueltas
- ✓ Principio iterativo y memoria de estado
- ☐ Arquitectura interna de una RNN (Próxima sesión)



Arquitectura y Funcionamiento de las Redes Neuronales Recurrentes (RNN)

El Estado Oculto, Modelado de
Lenguaje y Matemáticas de la
Recurrencia




Paradigmas de Procesamiento:

Red Convencional vs. Red Recurrente

	Red Convencional	Red Recurrente
Entrada	Un solo dato aislado (X). 	Dos flujos simultáneos: El dato actual (X_t) y la memoria histórica (h_{t-1}). 
Transformación	$X \rightarrow \text{Pesos } (W, b) \rightarrow Y$	Se aprovecha un punto intermedio del procesamiento para generar un <u>estado interno persistente</u>.
Memoria	Nula. Cada procesamiento es independiente.	Dinámica. El “<u>Estado Oculto</u>” <u>preserva el contexto</u> de los instantes anteriores.

El Motor de Memoria: El Estado Oculto (h_t)




Definición: El estado oculto no es la predicción final (Y_t). Es una representación interna que pasa entre instantes de tiempo.


Función: Actúa como la memoria central de la red, conteniendo la información codificada de las entradas procesadas en instantes de tiempo anteriores.

Aplicación Práctica: Modelado del Lenguaje


Contexto: Se le entrega al modelo una porción de texto y el objetivo es predecir la palabra siguiente paso a paso (ej. teclados predictivos en smartphones).



Flujo Secuencial: Iteración 1 ($t=1$)




El Enlace de Memoria: Iteración 2 ($t=2$)



La red no solo lee "una", sino que recuerda que antes vino "tienes" gracias a h_1 .

Propagación del Contexto: Iteración 3 ($t=3$)



Síntesis: En cada paso, la salida (y_t) se realimenta como entrada (x_{t+1}), acompañada de la actualización constante del estado oculto (h_t).

Anatomía Matemática I: El Estado Oculto (h_t)

$$h_t = \tanh(W_{xh} \cdot x_t + W_{hh} \cdot h_{t-1} + b_h)$$



Función de activación no lineal
para normalizar el nuevo
estado oculto entre -1 y 1.



Transformación del
dato de entrada actual
(coeficientes aprendidos).



Transformación de la
memoria histórica
(Estado Oculto previo).



Sesgo (bias)
aprendido durante el
entrenamiento.

El estado oculto se obtiene sumando las proyecciones lineales de la entrada actual y la memoria pasada.

Anatomía Matemática II: La Predicción (y_t)

Viene de la ecuación anterior

$$y_t = \text{Softmax}(W_{hy} \cdot \mathbf{h}_t + b_y)$$


El estado oculto recién calculado, actuando como base para la predicción.

Matriz de coeficientes que transforma el estado oculto en la salida.

Sesgo (bias) de la capa de salida.

Función de activación para generar la distribución de probabilidad sobre el vocabulario.


Arquitectura de Tensores I: Entrada y Memoria




Conclusión: Al sumar ambos vectores ($P \times 1 + P \times 1$), el nuevo estado oculto h_t mantiene una dimensionalidad compacta $P \times 1$, independiente del tamaño original del vocabulario (D).

Arquitectura de Tensores II:

Proyección de Salida




El Principio de Recurrencia Formalizada



Para calcular la activación actual, necesitamos no solo la entrada presente x_t , sino que existe una dependencia infinita hacia atrás con instantes de tiempo anteriores. Esta dependencia temporal, encapsulada en la variable de memoria h_{t-1} , es lo que otorga el nombre de red "recurrente" (RNN).


Representación Desplegada (Unrolled) en el Tiempo



Percepción Visual: A simple vista, parece que tuviéramos múltiples redes neuronales diferentes conectadas en cadena, una para cada iteración de la secuencia.


La Realidad: ¿Cómo evitamos una explosión exponencial de parámetros matemáticos al procesar secuencias largas? (Ver siguiente paso).

Unicidad de la Red: Parámetros Compartidos



- La red es una sola entidad física.
- Los parámetros (W_{xh} , W_{hh} , W_{hy} , b_h , b_y) son exactamente los mismos en cada iteración del tiempo.
- Compartir parámetros permite procesar secuencias de longitud infinita y variable manteniendo el tamaño de la arquitectura matemática estrictamente constante.

Síntesis Arquitectónica: Red Neuronal Recurrente



RNN Master Legend:

- **Red Única:** Parámetros compartidos en el tiempo.
- **Estado Oculto (h_t):** La memoria central preservada en dimensión compacta ($P \times 1$).
- **Propósito:** Proyectar el contexto histórico sobre la entrada presente para modelar secuencias complejas.