


Arquitectura y Funcionamiento de Redes Neuronales Recurrentes (RNN)

Análisis Topológico y Flujo Tensor a través del Tiempo



EL PROBLEMA SECUENCIAL



Predecir $N+1$ dado N

Flujo de memoria y dependencia secuencial

LA RESTRICCIÓN DE LA MÁQUINA

SECUENCIA DE LONGITUD VARIABLE

Palabra A

Palabra B

Palabra C

Palabra D



ENTRADA FIJA RNN

Vector de Entrada
(Tamaño Fijo)

El tamaño de las entradas en una RNN es estrictamente **FIJO**, pero la longitud de la secuencia de texto es **VARIABLE**.

Límite de arquitectura de hardware

La Cascada One-Hot

$V = 4$

tienes $\longrightarrow$ $[1, 0, 0, 0]$

una $\longrightarrow$ $[0, 1, 0, 0]$


única $\longrightarrow$ $[0, 0, 1, 0]$

oportunidad $\longrightarrow$ $[0, 0, 0, 1]$


Transformación a Ortogonalidad: Cada palabra se codifica como un tensor independiente de tamaño fijo **[4x1]**.

El Bucle Desenrollado

Rolled View




Unrolled View




El Estado Oculto (h_t): La memoria temporal del sistema que encapsula el contexto de las iteraciones anteriores.

El Motor Interno de un Nodo RNN



$$h_t = \text{Tanh}(W_{xh} \cdot x_t + W_{hh} \cdot h_{t-1} + B_h)$$

Mapa de Multiplicación Matricial




Compresión y Expansión: La red reduce el vector de vocabulario [4x1] a un estado denso [2x1], para luego expandirlo de vuelta a una predicción [4x1].

El Filtro Softmax

[4x1] Raw Vector



Softmax




'Winner Takes All': Softmax asigna probabilidades relativas (que suman 1.0) a cada posición del vector [4x1]. La posición con el valor máximo determina la palabra predicha.

Matriz de Arquitectura de Tensores


Transformación	Origen -> Destino (Dimensiones)	Matriz de Pesos (Dimensiones)	Función de Activación	Propósito en la Red
Entrada a Oculto	[4x1] -> [2x1]	W_{xh} [2x4]	Tanh	Extraer características de la palabra actual.
Oculto a Oculto	[2x1] -> [2x1]	W_{hh} [2x2]	Tanh	Mantener y actualizar el contexto de la secuencia.
Oculto a Salida	[2x1] -> [4x1]	W_{hy} [4x2]	Softmax	Mapear el estado interno a probabilidades del vocabulario.

El Arranque en Frío (t=1)




El Arranque en Frío (t=1): Como no hay contexto previo, la memoria inicial (h_0) se inyecta estrictamente como un tensor de ceros.

$t = 2$




$t = 3$



El bucle de memoria se densifica. Cada iteración recibe el vector exacto calculado en el paso temporal anterior.

Superposición Temporal



Compartición de Parámetros en el Tiempo: Los datos de entrada y el estado oculto mutan constantemente. Pero la arquitectura subyacente –los tensores W y B optimizados durante el entrenamiento– permanece matemáticamente idéntica en cada iteración.




Entrenamiento de RNN: Backpropagation a través del Tiempo (BPTT)

Mecánica del aprendizaje en secuencias temporales: desde el flujo hacia adelante hasta el gradiente acumulado.

El cambio de paradigma: Redes estáticas frente a secuencias temporales


El entrenamiento de una Red Neuronal Recurrente (RNN) comparte el ADN funcional de las redes Densas y Convolucionales: Forward y Backpropagation. Sin embargo, procesar secuencias dependientes exige una arquitectura extendida.

Redes Estáticas



- Datos independientes.
- Parámetros fijos asignados por capa.
- Un solo pase por dato.
- Error único evaluado al final del proceso.


Redes Temporales



- Datos secuenciales dependientes.
- Parámetros constantes a lo largo del tiempo.
- Estado oculto dinámico que funciona como memoria.
- Errores distribuidos y evaluados iterativamente.


Variables del sistema en el instante de tiempo t

- x_t **Entrada:** El dato específico de la secuencia en el instante actual.
- h_t **Estado Oculto:** La memoria dinámica del sistema.
- $\hat{y}_t$ **Predicción:** Estimación del valor real generada por la red.
- L_t **Error Individual:** Pérdida calculada (Entropía Cruzada). Diferencia entre la predicción y el Target.
- θ **Parámetros:** El set global de coeficientes (W, b). Únicos y constantes.




Expansión en el tiempo: Forward Propagation

Para entrenar una RNN, expandimos la **arquitectura** a través de la secuencia **temporal**. Aunque la visualización muestra múltiples nodos, es matemáticamente la misma red ejecutándose en diferentes instantes direccionales.




El vehículo temporal: Transmisión del estado oculto (h_t)

En cada iteración, la red combina la entrada actual (x_t) con el contexto del instante anterior. El estado oculto es la estructura de memoria que transmite esta información iteración tras iteración.



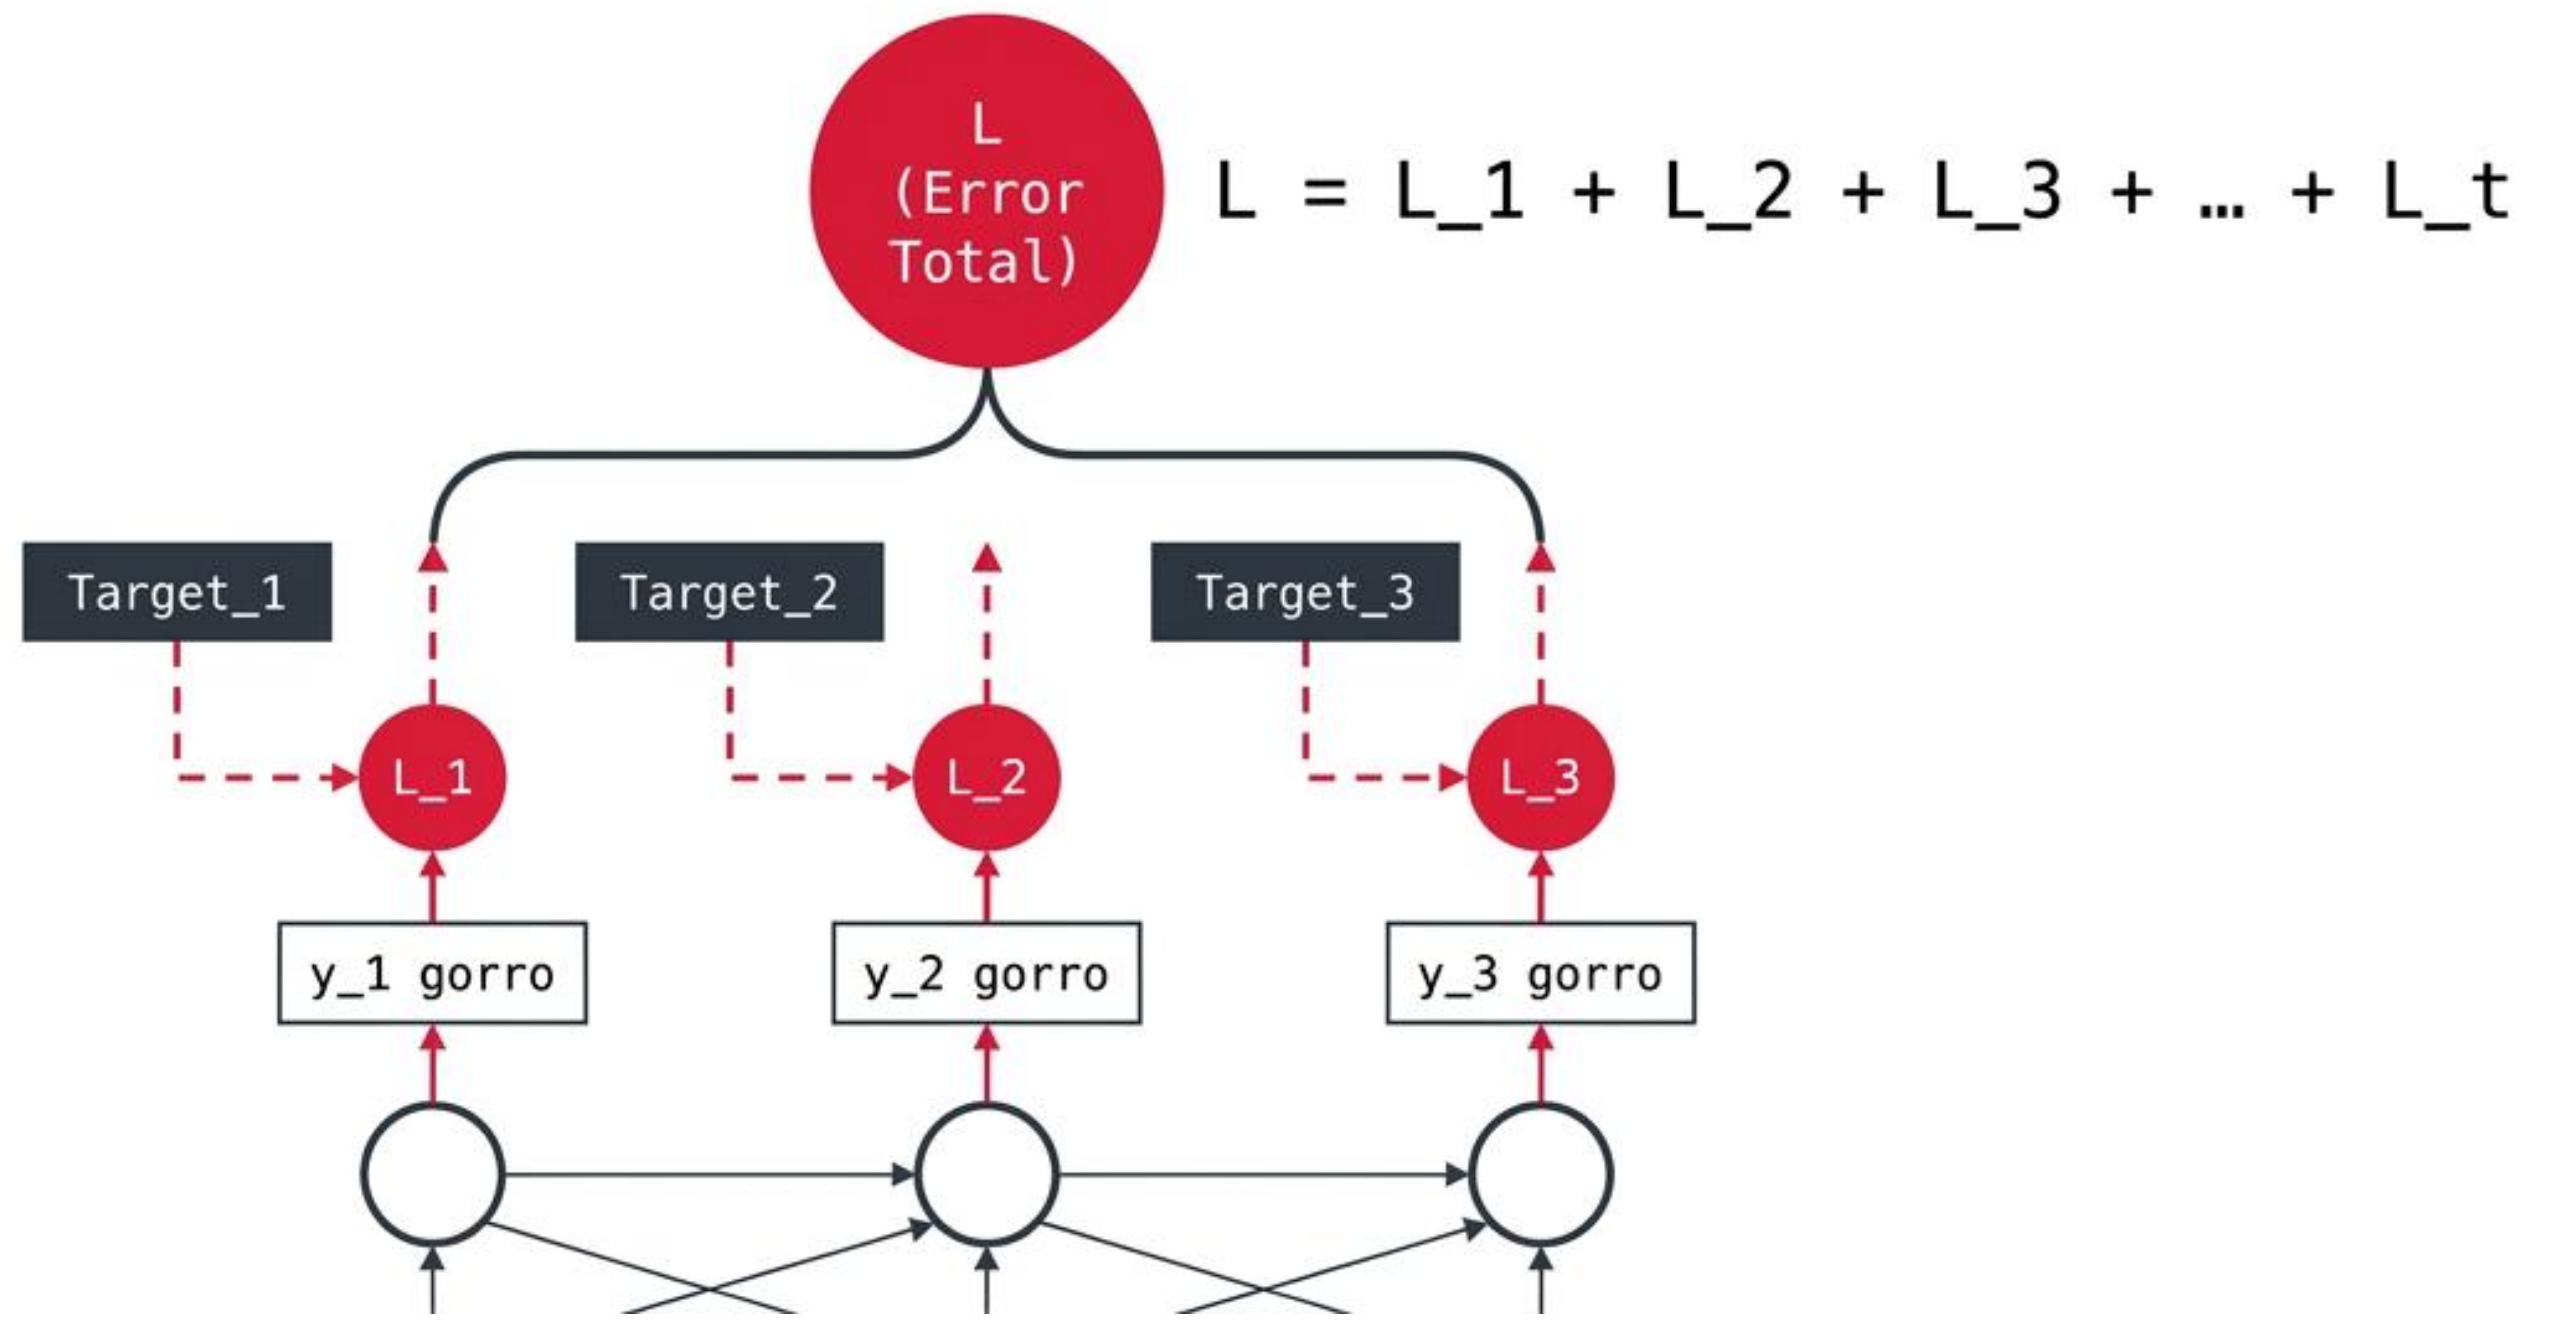
Invariabilidad estructural: Parámetros θ constantes

A diferencia de las redes estándar profundas donde cada capa posee pesos distintos, la RNN desenrollada aplica el mismo set de parámetros (θ) para procesar los datos en todos los instantes temporales.



Evaluación secuencial: Del error individual al costo total

Tras barrer la secuencia de entrada completa, se compara cada predicción con su valor de referencia. El Costo Total es la acumulación lineal de estos errores distribuidos en el tiempo.



Gradientes aditivos: La base matemática del BPTT

Para actualizar los coeficientes θ usando gradiente descendente, requerimos la variación del Error Total respecto a θ . Por linealidad, el gradiente total equivale a la suma exacta de los gradientes individuales generados en cada instante.

Actualización Objetivo


$$\theta_{new} = \theta_{old} - \alpha \nabla_{\theta} L$$

Suma de Gradientes

$$\frac{\partial L}{\partial \theta} = \frac{\partial L_1}{\partial \theta} + \frac{\partial L_2}{\partial \theta} + \frac{\partial L_3}{\partial \theta}$$


BPTT: Mecánica del flujo temporal inverso

Encontrar la derivada de L respecto a θ exige rastrear cómo un error puntual en el instante t es consecuencia de decisiones tomadas en el pasado. El flujo de cálculo matemático se invierte físicamente, viajando de derecha a izquierda.




Anatomía de una derivada: Dependencia directa en $t=3$

Al analizar el error final L_3 , su variación con respecto a θ requiere desenredar las transformaciones superpuestas mediante la Regla de la Cadena.



Memoria rastreada: La dependencia histórica de h_3


El verdadero reto técnico del BPTT radica en que el estado oculto final (h_3) no solo depende de θ en ese instante, sino de toda su historia algorítmica previa. Todo está interconectado en cadena.




Reducción de la cadena: Análisis de gradientes en $t=2$ y $t=1$

El proceso se repite para los errores registrados en instantes anteriores, pero las cadenas de derivadas se acortan progresivamente al no existir dependencia matemática hacia estados futuros.

Cálculo en $t=2$




Cálculo en $t=1$



Arquitectura del aprendizaje BPTT: Síntesis del ciclo

El algoritmo completo integra el paradigma temporal en tres pasos operacionales exactos para actualizar de manera global los parámetros del modelo secuencial.




Configuraciones y Aplicaciones de las Redes Neuronales Recurrentes

Adaptando la topología matemática a través del tiempo: de entradas únicas a secuencias complejas.



Una misma red, infinitas posibilidades topológicas

La arquitectura base de una RNN permanece inalterable. Su versatilidad para resolver problemas dispares radica exclusivamente en cómo enrutamos sus secuencias de entrada y salida a través del tiempo.



Disecccionando el flujo temporal: Convenciones de la arquitectura



x_t = Vector de Entrada. El dato ingerido por la red en el instante de tiempo t .




h_t = Estado Oculto. La celda recurrente que preserva la memoria y el contexto a través de las iteraciones.



y_t = Vector de Salida. La predicción o resultado emitido por la red en el instante t .


Configuración Uno-a-Varios: Proyectando un vector hacia una secuencia

Una única entrada inicial detona una reacción en cadena, generando una secuencia progresiva a través de múltiples iteraciones.




Aplicación Práctica: Generación de descripciones visuales (Image Captioning)

La red extrae las características del píxel en la primera iteración y utiliza su estado oculto para generar iterativamente la sintaxis correcta que describe la escena.




Configuración Varios-a-Uno: Colapsando secuencias en decisiones singulares

Procesamiento exhaustivo de una secuencia completa. La red acumula memoria iteración tras iteración antes de emitir un único resultado consolidado.




Aplicación Práctica: Análisis de sentimientos y clasificación de texto

La red retiene el contexto modificador (el "No" inicial) a lo largo de la secuencia para emitir un juicio categórico preciso al finalizar la lectura.



Configuración Varios-a-Varios (Asíncrona): El paradigma Codificador-Decoder

Las secuencias de entrada y salida no están alineadas. La red procesa la totalidad del estímulo inicial antes de comenzar a formular su respuesta progresiva.




Aplicación Práctica: Traducción automática de lenguajes

Traducir requiere el contexto íntegro de la frase original. El modelo captura la semántica en inglés antes de predecir la gramática correspondiente en español.


Phase 1 (Escuchar)

Phase 2 (Hablar)



Configuración Varios-a-Varios (Sincronizada): Procesamiento en tiempo real


Correspondencia uno a uno. La red está obligada a generar una salida inmediata en la misma iteración en la que recibe el dato de entrada.



Aplicaciones Síncronas: Modelado de lenguaje y análisis de video


Modelado de Lenguaje

Predicción del siguiente carácter o palabra. La salida actual alimenta la entrada futura.







Etiquetado de Video


Clasificación frame por frame.
A medida que ingresa cada imagen del video, se emite una etiqueta categórica simultánea.



Matriz de Diagnóstico Topológico RNN

Configuración	Topología (x -> y)	Sincronización	Aplicación Principal
Uno-a-Varios		Progresiva	Image Captioning
Varios-a-Uno		Colapsada	Análisis de Sentimientos
Varios-a-Varios		Asíncrona (Retraso)	Traducción de Idiomas
Varios-a-Varios		Síncrona (1:1)	Modelado de Lenguaje / Video

De la arquitectura matemática a la implementación en código



Con el funcionamiento interno, las reglas de entrenamiento y las configuraciones topológicas dominadas, el terreno teórico está asegurado.

Próximo hito: Desarrollo práctico en Python. Construiremos desde cero una red neuronal recurrente capaz de generar texto de forma autónoma.