



Implementación Práctica de Modelos de Lenguaje con RNN

De texto crudo a secuencias generativas mediante arquitecturas recurrentes.



EL CICLO DE VIDA DEL MODELO GENERATIVO



Paso 1:
Preparación
del Corpus
(Limpieza e
ingesta).


Paso 2:
Ingeniería de
Características
(Transformación
One-Hot).

Paso 3:
Arquitectura
en Keras
(Topología
SimpleRNN).

Paso 4:
Entrenamiento
y Generación
(Bucle
meurar
estocástico).

Paso 5:
Diagnóstico de
Resultados
(Análisis de
gradientes).

INGESTA Y LIMPIEZA DEL CORPUS



```
Project Gutenberg EBook
Author: Edgar Allan Poe
Release Date: ...
Language: English
Character set encoding: UTF-8

*** START OF THIS PROJECT GUTENBERG
EBOOK... ***
```

Eliminación total de encabezados y metadatos para evitar la inyección de ruido.

El barril de amontillado

Cientos de injurias de Fortunato había soportado como mejor pude, pero cuando llegó al insulto juré venganza. Vosotros, que conocéis tan bien la naturaleza de mi carácter, no supondréis...

Fuente de Datos: Cuentos de Edgar Allan Poe

Resultado: Un corpus de texto continuo y un vocabulario único extraído (Set) de exactamente 100 caracteres.

LA VENTANA DESLIZANTE (MECANISMO E/S)




Desplazamiento Iterativo: Un paso de 1 carácter hacia la derecha, barriendo la totalidad del texto continuo.

EL PUENTE LÉXICO: DICCIONARIOS DE CONVERSIÓN


Nota Técnica: El vocabulario total se reduce a 100 caracteres únicos.

	char2idx	
	' ' → 0	
	'G' → 1	
	'W' → 2	
	[...]	
	'k' → 99	



	idx2char	
	0 → ' '	
	1 → 'G'	
	2 → 'W'	
	[...]	
	99 → 'k'	


ANATOMÍA DEL TENSOR ONE-HOT



Transformación matemática completa:
El texto desaparece, emergiendo una matriz dispersa.

$$X_{train} \in \mathbb{R}^{(331,185 \times 10 \times 100)}$$

TOPOLOGÍA SECUENCIAL EN KERAS



PARADIGMA:

Modelo Sequential

NÚCLEO RECURRENTE:

Capa SimpleRNN masiva para capturar relaciones temporales locales.


CLASIFICADOR FINAL:

Capa Dense utilizando activación Softmax para emitir 100 probabilidades (una por cada carácter).

CARGA COMPUTACIONAL:

117,092 parámetros entrenables.

EL FLUJO DE RECURRENCIA (RED DESEENROLLADA)



Mecanismo de Memoria: La predicción en el instante T no solo depende de la entrada actual, sino del estado interno calculado en el paso $T-1$.

El tensor fluye a través de los 10 pasos de tiempo, acumulando contexto secuencial antes de emitir la predicción.

EL MOTOR DE OPTIMIZACIÓN

Optimizador

RMSprop

Eficaz para lidiar con gradientes en RNNs.

Función de Pérdida

Categorical Crossentropy

Estándar para clasificación multiclase.

Tamaño de Lote (Batch)

128


Muestreo aleatorio del corpus total de 331k ejemplos.

Ciclos de Entrenamiento

20 Épocas

Entrenado época a época para visualizar la extracción iterativa.

EL BUCLE DE GENERACIÓN ESTOCÁSTICA



Propósito: Predicción autónoma de bloques de 50 caracteres.

Mecanismo Crítico: La función `argmax()` busca implacablemente el índice con la máxima certeza matemática en el vector de salida. El carácter predicho colapsa desde la probabilidad y se reinyecta como entrada para la siguiente iteración.

EVOLUCIÓN COGNITIVA DEL MODELO

Época 0 (Ruido Aleatorio)

k%&asdf*p!ñmzx...

Inicialización estocástica. Ausencia total de reglas morfológicas.

Época 1 (Estructura Incipiente)

el cona to dores parta...

Aparición de fonemas y sílabas plausibles tras un solo barrido del corpus.

Época 20 (Sintaxis Local)

que la cabeza de la vista no sea parecida...

Palabras exactas formadas carácter a carácter. Se logra gramática local, aunque la coherencia semántica global sigue ausente.

DIAGNÓSTICO: EL CUELLO DE BOTELLA DE LA MEMORIA

de la cante en se había esta **de la cante**

Anomalía Detectada: Repetición en bucle al final de la secuencia.

Magnitud de la
Señal de Error

**Desvanecimiento del Gradiente
(Vanishing Gradient)**

Tiempo (Pasos hacia atrás)

Explicación: En arquitecturas SimpleRNN, la señal se atenúa exponencialmente durante la retropropagación en el tiempo, provocando amnesia secuencial.

SÍNTESIS ARQUITECTÓNICA Y PRÓXIMOS PASOS

Hito Alcanzado



Una topología simple de una sola capa aprendió vocabulario, espaciado y morfología del idioma español desde cero absoluto.

Barrera Estructural



Pérdida ineludible de contexto a largo plazo debido a la atenuación de gradientes matemáticos.

LA EVOLUCIÓN NECESARIA

Este modelo establece los fundamentos para transitar hacia arquitecturas con compuertas de memoria (LSTM / GRU), capaces de decidir computacionalmente qué recordar y qué olvidar.