


Arquitectura de las Redes LSTM



Compuertas y Celda de Memoria:
Deconstruyendo el flujo de información.

EL LÍMITE DE LA MEMORIA A CORTO PLAZO



INPUT STANDARD

Las RNN convencionales procesan el dato actual (x_t) junto con el estado oculto anterior (h_{t-1}).


EL PROBLEMA

Al extender la secuencia, la red sufre de gradientes que desvanecen.


CONSECUENCIA

Pérdida total de la capacidad para retener dependencias a largo plazo. La información antigua se diluye en cada iteración.

La celda de memoria: una vía principal ininterrumpida



Arquitectura de dimensiones espejadas



Para interactuar sin fricción matemática, el tamaño de la nueva celda de memoria no es arbitrario.

Si el estado oculto (h_{t-1}) tiene una representación vectorial de tamaño $P \times 1$...


La representación vectorial de la celda de memoria es exactamente $P \times 1$.

Controlando el flujo: Las tres compuertas

Para incluir o eliminar información de la celda de memoria de forma selectiva, la arquitectura LSTM emplea un sistema de compuertas.

1. **Compuerta de Olvidar (Forget)**
2. **Compuerta de Entrada (Input)**
3. **Compuerta de Salida (Output)**

Insight Técnico: Cada compuerta actúa como una válvula de precisión para el flujo de información vectorial.



Anatomía de una compuerta: Pequeñas redes neuronales

Las tres compuertas operan con un mecanismo interno idéntico, entrenado como una red convencional.

Entradas


El dato actual (x_t) y el estado oculto anterior (h_{t-1}).

Transformación

Ponderación mediante coeficientes de peso (W) y un coeficiente de bias (b), aprendidos durante el entrenamiento.

Activación Sigmoidal (σ)

Comprime la salida a un valor entre 0 y 1. (0 = Válvula totalmente cerrada; 1 = Válvula totalmente abierta).



Compuerta 1: Forget (Olvidar)

Misión

Aprender a determinar qué cantidad de información de la celda de memoria anterior se va a preservar.


Mecanismo

La salida sigmoideal $[0,1]$ se combina directamente con el vector de la memoria a largo plazo que viene del instante de tiempo anterior.

Efecto

Si la válvula arroja un 0, la información histórica se elimina radicalmente de esa dimensión vectorial.

C_{t-1}



Compuerta 2: Entrada (Input)

Misión


Decidir qué información nueva (basada en el dato actual x_t) vale la pena agregar a la celda de memoria.

Mecanismo

Actúa como un filtro estricto. Analiza el contexto actual e histórico para asignar una puntuación de relevancia $[0,1]$ a los nuevos datos entrantes.

Efecto

Previene que ruido irrelevante contamine la autopista de memoria a largo plazo.



Compuerta 3: Salida (Output)

Misión


Determinar qué fracción de la celda de memoria actualizada se va a transmitir como el nuevo estado oculto (h_t).

Mecanismo

Filtra la memoria a largo plazo para extraer solo los elementos necesarios para el instante actual.

Efecto

Permite que la red exponga selectivamente su memoria a largo plazo para realizar la predicción inmediata sin revelar todo su contenido.



El motor de contenido: La celda de memoria candidata

Misión


Procesar x_t y h_{t-1} para generar la información nueva potencial que se podría añadir a la memoria.

Diferencia Matemática

Utiliza una función de activación Tangente Hiperbólica (Tanh) en lugar de una Sigmoidal.

¿Por qué Tanh?


En las RNN estándar, el estado oculto se calcula con Tanh. Esto mantiene la salida en una escala de $[-1, 1]$, preservando el mismo manejo matemático de la información.



Matriz Arquitectónica: Control vs. Creación

	Las Compuertas (Control)	Celda Candidata (Contenido)
Componentes	Forget, Input, Output	Celda Candidata
Función Base	Redes neuronales pequeñas con coeficientes W, b	Red neuronal pequeña con coeficientes W, b
Activación	Sigmoide (σ)	Tangente Hiperbólica (Tanh)
Rango Matemático	$[0, 1]$ (Magnitudes)	$[-1, 1]$ (Dirección y Magnitud)
Rol Lógico	Actúan como Filtros/Válvulas	Actúa como Generador de Nueva Información

El Blueprint LSTM: El circuito completo



Integración

Los cuatro elementos neuronales (3 compuertas de filtrado + 1 celda candidata de generación) operan en paralelo sobre las mismas entradas.

El Próximo Paso


En la siguiente fase, estas válvulas interactuarán matemáticamente mediante multiplicación y suma matricial para calcular el estado exacto de C_t y h_t .

Conclusión


La LSTM no almacena memoria por arte de magia; construye un sofisticado sistema de fluidos de información, regulado por gradientes aprendidos.

Mecánica de Actualización y Flujo de Información en Redes LSTM

Anatomía técnica de dependencias a largo y corto plazo




Integración de Dependencias: El Paradigma LSTM



La Autopista Principal: Información de Largo Plazo

El estado de la celda (C_{t-1}) transporta la información a través de toda la secuencia.



1. Eliminación:

¿Qué información histórica ya no es relevante?

2. Adición:

¿Qué datos nuevos merecen ser preservados para el futuro?

Compuerta 'Forget': El Filtro de Relevancia

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

Función:


Decide si la memoria del instante anterior (C_{t-1}) se preserva o se elimina.

Mecánica:

Genera un vector con valores entre 0 y 1.


Impacto:

Multiplicar por ≈ 0 borra el término (información irrelevante). Multiplicar por ≈ 1 preserva el término para el futuro.



Generación de la Celda Candidata ($\tilde{C}_t$)

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$



- Propósito: Extraer la nueva información contenida en el estado oculto anterior y el dato de entrada actual.
- Escalado: La función tangente hiperbólica ($\tanh$) comprime los valores en un rango estandarizado de -1 a 1 .
- Estado: Es una propuesta. Aún requiere validación antes de integrarse a la memoria principal.

Compuerta de Entrada: Validando Nueva Información


$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

- **Decisión:**

Determina qué fracciones de la celda candidata ($\tilde{C}_t$) valen la pena introducir a la memoria a largo plazo.

- **Filtro:**

Al igual que la compuerta 'Forget', actúa como una llave maestra.




Valores cercanos a 0:
Ignora el dato candidato.

Valores cercanos a 1:
Aprueba el paso de la nueva información.

El Nuevo Estado de la Celda (C_t)

$$C_t = f_t \otimes C_{t-1} + i_t \otimes \tilde{C}_t$$



La actualización de la memoria principal es una combinación puramente aditiva de dos fases:

- **1. Retención:**
Lo que decidimos no olvidar del pasado.
- **2. Adquisición:**
La nueva información que pasó nuestro filtro de entrada.

A través de cada iteración del entrenamiento, la red aprende qué elementos son vitales para preservar.


Reescalando la Memoria para el Corto Plazo

El nuevo estado a largo plazo (C_t) contiene la información más pura y actualizada.

Para integrarlo en la memoria de corto plazo, debe ser normalizado.

El Rol de tanh:

La función tangente hiperbólica **reescala** los valores de la celda nuevamente al rango de -1 a 1 , haciéndolos matemáticamente **comparables para el siguiente paso**.



Compuerta de Salida: El Filtro Final de Exposición

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

Determina qué partes del estado de la celda actualizado (C_t) son relevantes de inmediato.

La compuerta analiza el contexto anterior y el dato contexto anterior y el dato actual para abrir o cerrar el flujo de información hacia el exterior.



Salida ≈ 0 :
Información bloqueada.

Salida ≈ 1 :
Información expuesta.


Generación del Nuevo Estado Oculto (h_t)

$$h_t = o_t \otimes \tanh(C_t)$$


La multiplicación elemento a elemento culmina el proceso interno de la celda.

La información de largo plazo, filtrada por la compuerta de salida, se convierte oficialmente en la memoria de corto plazo actual (h_t).

Este vector se bifurca: se transmite al siguiente instante de tiempo y se envía como salida del bloque LSTM.



De la Celda a la Predicción del Modelo




El estado oculto actualizado (h_t) proporciona el contexto, pero no es la salida final.

Sigue la lógica de una red neuronal clásica: el vector h_t se transforma mediante una matriz de coeficientes (W) y sesgos (b) aprendidos durante el entrenamiento.

Esta transformación adapta la memoria puramente secuencial al dominio específico del problema.

Adaptación de la Salida: Softmax vs. Sigmoidal

La función de activación final sobre los datos transformados dicta el tipo de predicción.




El Fin del Desvanecimiento del Gradiente

RNN Clásica Desvanecimiento del Gradiente



En redes recurrentes convencionales, las multiplicaciones continuas por valores < 1 hacen que los gradientes de retropropagación desaparezcan.

LSTM




La conexión aditiva ($\oplus$) en la memoria de largo plazo actúa como una superautopista. Permite que la información y los gradientes fluyan hacia atrás sin degradarse, resolviendo el "Gradient Vanishing" y logrando un balance perfecto entre secuencias largas y cortas.

Matriz de Diagnóstico: Arquitectura de la Memoria

Memoria de Largo Plazo (C_t)	Estado Oculto / Corto Plazo (h_t)
Arquitectura de Red Autopista superior ininterrumpida	Arquitectura de Red Ruta inferior altamente interactiva
Mecanismo de Actualización Actualización puramente aditiva ($\oplus$)	Mecanismo de Actualización Actualización multiplicativa por compuertas ($\otimes$)
Función Contextual Conserva historia lejana y resuelve gradientes	Función Contextual Provee contexto local inmediato y genera la predicción actual.

El Circuito Unificado LSTM



Un flujo constante, selectivo y matemáticamente preciso.

El entrenamiento de la red LSTM no es más que enseñar a este sistema de válvulas a encontrar el equilibrio perfecto de retención y exposición a lo largo del tiempo.